



---

## 导读

在AI训练集群规模飙升至数万张GPU的时代，英伟达早已超越硬件供应商的角色，成为定义计算平台未来的核心力量。这场访谈中，黄仁勋回溯了从GeForce时代强行植入CUDA的痛下赌注，到为突破万卡瓶颈而被迫进行GPU、网络、电源全栈协同设计的历程，揭示了英伟达如何凭借安装基数信念、系统重构能力和“AI工厂”的战略定位，构筑起难以撼动的产业壁垒。他还清晰地描绘了AI扩展法则的下一个前沿：推理与智能体驱动将打破数据墙，让计算成为智能无限扩展的唯一燃料。而这些连续性重大决策背后的运转引擎，正是其扁平化组织与信念塑造领导哲学。

---

## 核心结论

- 通过从加速器到AI工厂的定位转变与GeForce强行搭载CUDA的豪赌，英伟达以安装基群压倒架构优雅，奠定AI计算平台不可逆转的优势：在专业化与通用化之间的窄路上，英伟达利用消费级GeForce的巨大装机量强行植入CUDA，虽然短期内几乎吞噬全部毛利并使市值暴跌，却借此将超级计算能力送入全球研究者手中，最终使GeForce成为深度学习革命的孵化平台。这一战略证明，安装用户基数才是决定计算平台命运的唯一最重要因素。
- 万卡级AI训练迫使英伟达走向极致协同设计，全系统重构构成其核心技术与生态壁垒：当AI训练规模扩展到数万张GPU时，阿姆达尔定律使得单纯加速单个芯片失效，网络、存储、电源、散热等每一个组件都成为瓶颈。英伟达由此被逼进行从芯片到机架、从供电到冷却的端到端协同设计，这种全系统整合能力是其他竞争对手难以复制的护城河。

- **AI扩展法则**已进入推理与智能体驱动的新阶段，计算取代数据成为唯一限制，并将催生无限智能循环：合成数据打破了预训练的数据墙，使计算能力成为扩展的真正瓶颈。更关键的是，推理阶段的思考、规划和搜索远比预训练更消耗算力，推理将成为未来最大的计算市场。而智能体系统能够自主生成新数据和经验，形成“数据生成-训练-再生成”的无限循环，让智能几乎可以持续扩展。
- **黄仁勋的扁平化组织与信念塑造领导哲学**，为英伟达连续做出重大正确决策提供了内部运转引擎：通过管理60名直接下属、取消一对一会议、将公司设计为创新机器，并通过每日逐步分享推理过程来塑造团队的信念体系，黄仁勋使得收购Mellanox这类重大决策在提出时已被整个组织认为理所当然。这种领导模式极大地减少了战略决策的内在阻力，确保了长期战略的严格执行。

---

## 观点拆解

### 1. 在GeForce上强行搭载CUDA的豪赌，奠定了英伟达在深度学习革命中的不可逆转基础

- **装机基数比架构优雅更能决定计算平台的命运**：黄仁勋以x86和众多失败的精美RISC架构为例，明确指出安装用户基数才是定义架构成功与否的单一最重要因素，而非设计的优雅程度。这一洞察直接驱动了英伟达不惜代价在GeForce上强行普及CUDA的战略决策。 [10:42](#)

“安装基础就是一切。安装基础定义了一种架构，而不是其他一切都是次要的。” [12:59](#)

- **将CUDA植入消费级GeForce是短期极度痛苦但长期不可逆的豪赌**：英伟达选择在已经年销数百万片的GeForce游戏显卡上强行搭载CUDA，虽然这大幅推高了芯片成本、几乎吞噬全部毛利，并使市值从约80亿美元崩跌至约15亿美元，却也把超级计算能力送进了每一台PC，让全球的研究人员、学生和科学家都能在自己的电脑上实践加速计算，进而自发形成装机集群，最终将GeForce变成了深度学习革命不可替代的孵化平台。 [10:42](#)

“我们应该在 GeForce 上安装 CUDA。” [13:35](#)

“我意识到它会增加代价很大，但这是我们相信的。我们的市值跌到了大约15亿美元。” [14:46](#)

“GeForce 将 CUDA 技术普及到了所有人。然后，它就成为了平台。深度学习革命的基础。” [15:07](#)

- **强烈的技术信念与日常信念塑造驱动了这场高风险战略**：黄仁勋基于深度推理形成了一种不可动摇的确信——加速计算一定会发生。他不仅在管理层构建这一信仰，更通过日复一日的

日常沟通不断将其灌输给整个组织，使得当最终决策做出时，对所有人而言都已经是一件“理所当然”的事。这种信念引擎正是支撑CUDA豪赌穿越至暗时刻的内在动力。 [10:42](#)

“我内心深信不疑。当我相信的时候，你创造未来。而那个未来如此令人信服，这事一定会发生。”

[17:35](#)

## 2. 从加速器公司到AI工厂，英伟达在专业化与通用化的张力中走出独特路径

- 纯粹的加速器定位因市场狭窄而限制研发与影响力，英伟达不得不寻求超越：英伟达最初是一家高度专业化的加速器公司，但这种定位虽然性能极致，却面临应用领域过窄的困境。市场规模直接决定了研发能力，进而决定企业能产生的影响力，因此意识到必须走出加速器的局限。

“问题市场规模也决定了你的研发能力。以及你们的研发能力最终决定影响力和你可能产生的影响计算机。” [08:04](#)

- 专业化与通用化之间存在根本张力，英伟达选择在窄路上逐步扩展计算能力而不放弃专长：成为计算机公司会削弱目的性与专业性，而越专精则计算通用性越低，两者难以兼得。Jensen提出必须将‘计算机’与‘加速器’这两个词连接起来，在极窄的中间地带一步一步扩大计算能力，同时牢牢守住核心专长。

“我们这家更好的计算机公司变得越糟糕，我们就越专家。越是专家，我们整体的产能就越少。”

[08:41](#)

“我将这两个词连接起来公司必须找到的那条非常狭窄的小路，一步一步地扩大我们计算能力的一步但不要放弃最重要的事我们拥有的专业技能。” [08:52](#)

- 在GeForce上安装CUDA是实践窄路的关键决定，以消费安装基础推动通用平台，奠定AI革命基础：面对计算平台依赖安装基础的现实，英伟达利用已销售的百万级GeForce GPU作为起点，强行引入CUDA以培养开发者生态，即使短期内大幅消耗利润、市值暴跌也坚持投入。这一战略最终将加速器推向通用计算平台，成为深度学习革命的基座。 [00:33](#)

“我们做出的决定是这样的：那很好，我们说，嘿，看，归根结底，这取决于用户基数。我们获得新的计算架构融入世界的最佳途径是什么？到那时，GeForce已经成为成功的。我们当时已经在销售数以百

万计的GeForce GPU年。我们说，我们应该在GeForce上安装CUDA，并将其放入每一台电脑中，并将其作为我们培养已安装用户群的起点。” [13:14](#)

“CUDA发布之后，我意识到它会增加代价很大，但这是我们相信。你知道，我们的市值跌到了大约15亿美元。虽然我们一路披荆斩棘。缓慢地返回，但我们继续进行CUDA训练。GeForce。” [14:42](#)

### 3. 极致协同设计是英伟达应对万卡级AI算力的唯一出路

- 阿姆达尔定律倒逼全系统协同设计：当AI训练扩展到数万张GPU时，仅仅加速单个芯片对整体性能的提升极其有限。黄仁勋指出，如果计算只占问题工作负载的一半，即便把计算速度无限提升，也只能带来2倍的整体加速。这意味着必须拆解算法、重构管道并对模型进行分片，从而迫使网络、存储、电源等所有组件一起进行极致协同设计。 [00:33](#)

“这就是AMD娃娃定律问题 你加速的幅度是多少？某事取决于多少这就是全部工作量。所以如果计算结果占50% 问题，我加快了计算速度。无限次，就像你知道的一百万次一样。我只是将总工作量提高了a 2 倍。” [02:02](#)

- 万卡级分布式计算将所有组件都变成性能瓶颈：在数千乃至上万张GPU互联的规模下，单纯提升某一部分已经失效。黄仁勋强调，此时CPU、GPU、网络连接、交换机以及工作负载分配同时成为问题，整个计算机变得极其复杂。因此必须进行从芯片到机架、从供电到冷却的端到端协同设计，才能让系统真正提速。 [00:33](#)

“因此，分布式计算在我们所达到的规模，CPU是个问题，GPU是个问题，网络连接有问题。切换是个问题，而且将工作负载分配到所有这些电脑有问题。它只是一台极其复杂的计算机。” [02:47](#)

### 4. AI扩展法则已进入推理与智能体时代，计算而非数据成为唯一限制

- 合成数据打破预训练数据墙，计算成为扩展的唯一瓶颈：黄仁勋指出，行业曾一度恐慌于预训练数据枯竭，但面向未来，合成数据可以近乎无限地生成和扩充，使预训练不再受限于数据，真正的扩展瓶颈已经转移到计算能力上。

“我们数据用完了.....整个行业陷入恐慌。显然这不是真的。我们将不断扩大数据规模，其中很多很可能是合成数据。” [23:48](#)

“我们到了不再受限于数据的临界点，训练现在被计算能力所限。” [25:09](#)



- 推理的思考难度远超预训练，测试时计算将使推理成为最大市场：黄仁勋反驳了“推理很容易”的流行观点，强调推理本质上是思考、计划和搜索，远比预训练的“阅读”更困难，测试时间缩放需要极大的算力，这将推动推理成为未来最大的计算市场，而非一个可以被商品化的廉价任务。 [00:33](#)

“在未来，推理将成为最大的市场。” [25:42](#)

“推理就是关于思考、计划和搜索……测试时间缩放是计算量极大的。” [26:45](#)

- 智能体尺度定律：智能体系统生成数据并形成训练闭环，智能可以无限扩展：黄仁勋描绘了一个新的智能体尺度定律：智能体系统能够主动产生大量经验和数据，这些数据会回流到预训练和后训练阶段，形成一个永不停止的“数据生成-训练-再生成”循环，使智能摆脱数据限制，持续向上扩展。 [04:54](#)

“当我们使用智能体系统，它们会生成更多数据，创造丰富的体验……这个数据集会一路回流到预训练阶段。” [28:01](#)

“这个循环将会一直持续下去，永无止境……智能将无限扩展。” [28:31](#)

## 5. 黄仁勋以扁平组织和信仰塑造为核心的领导哲学驱动英伟达的长期战略

- 扁平组织与“公司即机器”的设计哲学：黄仁勋将英伟达视为一台持续产出创新的机器，为此他直接管理60名下属，取消一对一会议，打破信息壁垒，以组织架构本身驱动透明、高速的决策循环。 [00:33](#)

“公司的目标就是成为一台机器，一个能够系统性地输出我们乐于创造的产品机制。” [05:22](#)

“我的直接下属有60人，我没有一对一会议，这是不可能的，你不能让60个人都在你的直接管理层里。” [05:42](#)

- 通过持续分享推理塑造组织信念体系，实现零阻力决策：黄仁勋认为领导力的核心不是突然发布宣言，而是每天逐步向团队展示自己的推理过程，潜移默化地塑造集体的信念体系。正

因如此，当他最终提出收购Mellanox时，整个组织已经将其视为水到渠成的必然选择。

04:54

“我每天都会塑造他人的信仰体系，对我的管理团队和员工也是如此，这样当我提出收购Mellanox时，大家会觉得这是显而易见的决定。” 19:22

“每当我了解新事物，它就会影响我的思考方式，我会确保让周围的人明白。我是一步一步地思考问题的。” 18:47

---

## 总结

英伟达真正的护城河并非单一的GPU领先，而是从消费级安装基数中强行生长出的CUDA生态、因应万卡挑战而炼成的全系统协同设计能力，以及黄仁勋为组织植入的长期信念体系。这三重优势使其在AI计算平台上拥有了类似x86早期般的绝对控制力。更深远的是，当AI扩展进入推理与智能体自生成数据的无限循环后，计算需求将不再受数据约束，英伟达作为最主要的算力提供者，其增长空间与战略重要性将被重新定义。因此，押注英伟达本质上是在押注一个计算成为唯一资源、智能可以永续扩展的未来世界。

---

## 来源信息

- 标题: Jensen Huang: NVIDIA - The \$4 Trillion Company & the AI Revolution | Lex Fridman Podcast #494
  - 作者: Lex Fridman
  - 链接: <https://www.youtube.com/watch?v=vif8NQcjVf0>
  - 时长: 2:25:58
-